INFORME DE AUDITORÍA DEL MODELO STUDENT
Semana 15 · OBAS V2 · Segmentación de áreas quemadas · Galviz, Falla y Peña

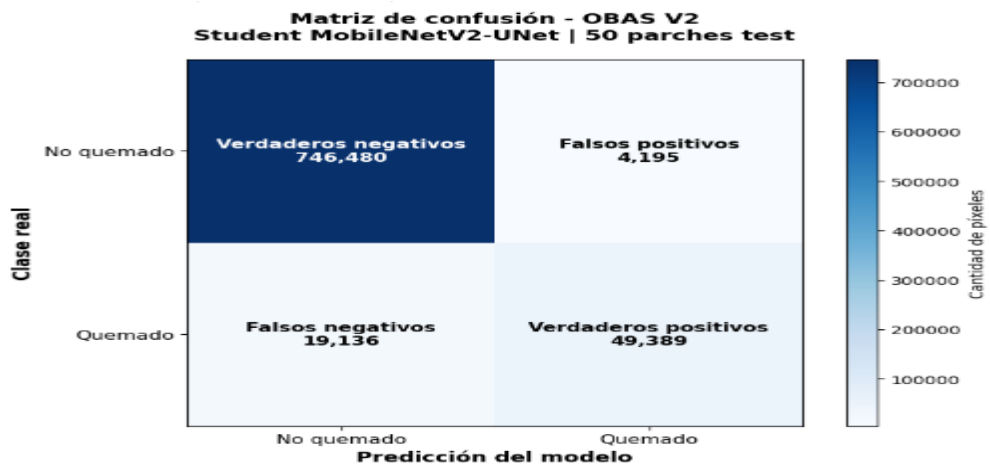
1. Objetivo y alcance

Se auditó el modelo Student MobileNetV2–UNet V2 para segmentación binaria de píxeles quemados y no quemados en parches satelitales de 128 × 128 píxeles. La evaluación principal utilizó 50 parches seleccionados del índice patch_index_spatial_v2.csv y marcados como test, procedentes de OBAS_zone1, OBAS_zone2, OBAS_zone3 y CEMS_AOI01_01. Se utilizó el umbral de segmentación de 0,5. La selección fue estratificada y no reproduce necesariamente la prevalencia del conjunto completo.

2. Desempeño cuantitativo

Indicador	Resultado	Indicador	Resultado
Precision	92,17 %	Recall	72,07 %
F1 / Dice	80,89 %	IoU	67,92 %
Accuracy	97,15 %	Average Precision (PR)	0,9116
Latencia media en Kaggle	253,31 ms	Parches evaluados	50

Matriz de confusión por píxel: verdaderos negativos (TN) = 746.480; falsos positivos (FP) = 4.195; falsos negativos (FN) = 19.136; verdaderos positivos (TP) = 49.389. La accuracy debe interpretarse con cautela por el predominio de píxeles no quemados. El recall del 72,07 % indica que aproximadamente el 27,93 % de los píxeles quemados de esta muestra no se detectaron.



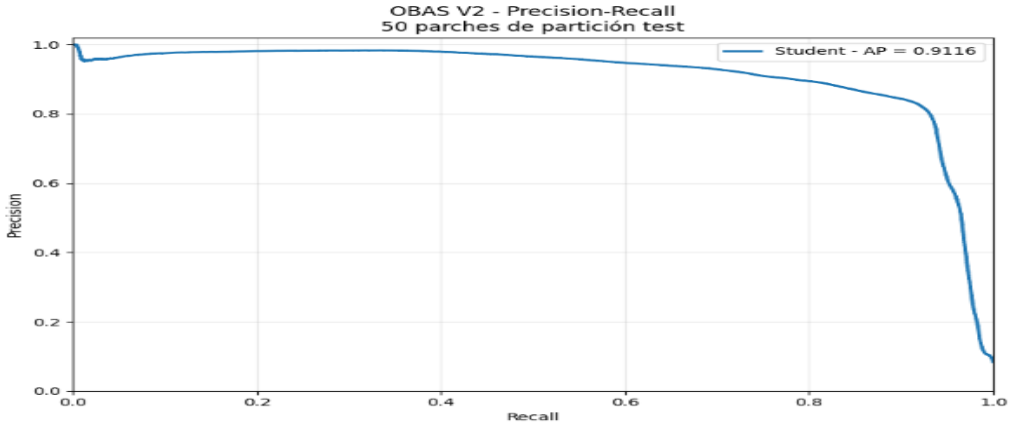

```
=== MATRIZ DE CONFUSIÓN ===
[[746480   4195]
 [ 19136  49389]]

Imagen guardada en:
/kaggle/working/OBAS_V2_Auditoria_50_TEST/S15_Matriz_Confusion_50_TEST.png

Total de píxeles evaluados: 819200
```

3. **Curva Precision–Recall y umbral**

```
=== CURVA PRECISION-RECALL: 50 TEST ===
```



El Average Precision fue 0,9116. A umbral 0,3 se obtuvo precision 91,76 %, recall 73,20 % y F1 81,44
%; a 0,5, precision 92,17 %, recall 72,07 % y F1 80,89 %; a 0,9, precision 93,83 %, recall 65,17 % y F1 76,92 %. Se conserva 0,5 como umbral de referencia: escoger otro umbral usando el propio test introduciría sesgo de selección.

4. **Tres clases de peor desempeño: aclaración metodológica**

La rúbrica solicita “tres clases con peor desempeño”, pero este modelo no predice tres clases: solo distingue píxel quemado y no quemado. No sería válido inventar categorías semánticas. Para atender el análisis de fallos se reportan en la página siguiente tres tipos de error, que no deben confundirse con clases del modelo.

HALLAZGOS, RIESGOS Y ROBUSTEZ

5. Tres tipos de error más relevantes

Tipo de fallo	Evidencia en los 50 parches	Consecuencia potencial
Omisión completa de quema	5 parches positivos sin píxeles detectados	Una zona quemada puede pasar inadvertida.
Subestimación de área quemada	20 parches con detección parcial; 19.136 FN globales	Estimación incompleta de la extensión y priorización inadecuada.
Predicción fuera de la región real / falsa alarma	1 parche positivo sin superposición y 1 parche negativo con falsa alarma	Inspecciones innecesarias o localización equivocada.

El análisis por parche clasificó además 23 casos sin quema correctamente identificados. Entre los fallos relevantes, CEMS_AOI01_01_000060 presentó 12.587 píxeles quemados reales y 8.181 falsos negativos (F1 = 0,5013). Algunos parches omitidos contienen solo 1 a 7 píxeles quemados; su F1 nulo no debe interpretarse como un fallo de la misma magnitud que la omisión de una zona extensa.

6. Robustez ante perturbaciones

En una evaluación exploratoria anterior de 20 parches, el F1 global fue 0,7658 en condiciones originales; con desenfoque (blur), 0,0000; con reducción de iluminación, 0,4015; con oclusión, 0,7168; y con cambio de fondo, 0,3143. La caída ante desenfoque y cambios visuales indica una vulnerabilidad importante a alteraciones de la entrada. Estas pruebas no son equivalentes a una validación de campo.

7. Estabilidad y tres semillas

Se utilizaron las semillas 42, 123 y 2026 para remuestreo bootstrap de 20 parches, obteniendo F1 de 0,6413; 0,7270 y 0,7417, respectivamente. Este ejercicio caracteriza sensibilidad a la composición de la muestra, pero no equivale a entrenar y evaluar tres modelos independientes, como podría exigir una interpretación estricta de la rúbrica.

8. Interpretabilidad mediante Grad-CAM

Se generaron y verificaron 20 figuras de atribución sobre la capa decoder4_conv2 (64 × 64 × 32): diez detecciones positivas de mejor F1 y diez casos positivos de menor F1. Los gradientes fueron finitos y los archivos se abrieron correctamente. En cinco omisiones completas, el objetivo de atribución se definió mediante la máscara real y se rotuló como diagnóstico guiado por referencia; no representa una detección que el modelo haya efectuado. Los mapas Grad-CAM son explicaciones aproximadas y no prueban causalidad.

9. Consecuencias para el usuario y recomendaciones

Uso recomendado: herramienta de apoyo para revisión humana y priorización exploratoria de áreas potencialmente quemadas, no sistema autónomo para alertas críticas, decisiones de emergencia, cuantificación oficial de daños ni descarte definitivo de incendios. Una omisión puede subestimar afectaciones; una falsa alarma puede desviar recursos; una máscara mal localizada puede orientar incorrectamente una inspección.

Antes de desplegar: (1) recuperar el manifiesto de entrenamiento y verificar particiones espaciales y ausencia de fugas; (2) evaluar regiones verdaderamente externas; (3) completar tres entrenamientos independientes si la rúbrica lo requiere; (4) investigar la fragilidad frente a blur y cambios de iluminación; (5) calibrar confianza y fijar umbrales con validación, no con test; (6) medir latencia y errores en la aplicación y documentar 50 capturas regionales reales; (7) incorporar revisión humana y mecanismos de aviso ante incertidumbre.

10. Evidencias y trazabilidad de la entrega

El cuaderno Kaggle S15_Auditoria_Galviz_Falla_Pena contiene la ejecución de métricas, curva PR, análisis de errores, robustez, bootstrap y Grad-CAM. El respaldo S15_Evidencias_Auditoria_OBAS_V2.zip reunió 50 archivos y superó la comprobación de integridad.

Se generaron los archivos S15_metricas_globales_50_TEST.csv, S15_resumen_auditoria_50_TEST.json, S15_curva_precision_recall_50_TEST.png y las 20 figuras Grad-CAM. El enlace GitHub

Conclusión. El Student mostró buena precisión (92,17 %) y AP (0,9116), pero recall limitado (72,07 %), omisiones significativas y alta sensibilidad a ciertas perturbaciones. Su utilización debe mantenerse supervisada hasta completar la validación independiente y de campo.